

라오-크라머 한계&효율성

정의

- 개요

1. 불편추정량의 분산의 하한을 결정하는 방법을 다룬다.
2. 우도함수를 이계 미분한 피셔정보행렬을 활용한다.

- 유도

1. $1 = \int_{-\infty}^{\infty} f(x; \theta) dx$ 인 함수가 있다고 하자.

1) 이 식을 θ 에 대해 미분하면

$$(1) \quad 0 = \int_{-\infty}^{\infty} \frac{df(x; \theta)}{d\theta} dx = \int_{-\infty}^{\infty} \frac{df(x; \theta)/d\theta}{f(x; \theta)} f(x; \theta) dx \quad \text{혹은} \quad \int_{-\infty}^{\infty} \frac{d \log f(x; \theta)}{d\theta} f(x; \theta) dx$$

$$(2) \quad \text{위 식을 한번 더 미분하면} \quad \int_{-\infty}^{\infty} \frac{1}{d\theta} \left[\frac{d \log f(x; \theta)}{d\theta} f(x; \theta) \right] dx$$

$$= \int_{-\infty}^{\infty} \frac{d^2 \log f(x; \theta)}{d\theta^2} f(x; \theta) dx + \int_{-\infty}^{\infty} \frac{d \log f(x; \theta)}{d\theta} \frac{df(x; \theta)}{d\theta} dx$$

$$= \int_{-\infty}^{\infty} \frac{d^2 \log f(x; \theta)}{d\theta^2} f(x; \theta) dx + \int_{-\infty}^{\infty} \frac{d \log f(x; \theta)}{d\theta} \frac{df(x; \theta)/d\theta}{f(x; \theta)} f(x; \theta) dx$$

$$= \int_{-\infty}^{\infty} \frac{d^2 \log f(x; \theta)}{d\theta^2} f(x; \theta) dx + \int_{-\infty}^{\infty} \frac{d \log f(x; \theta)}{d\theta} \frac{d \log f(x; \theta)}{d\theta} f(x; \theta) dx$$

정의

- 유도

2) 이계 미분한 적분식을 기댓값 형태로 고치면

$$(1) \int_{-\infty}^{\infty} \frac{d^2 \log f(x; \theta)}{d\theta^2} f(x; \theta) dx + \int_{-\infty}^{\infty} \frac{d \log f(x; \theta)}{d\theta} \frac{d \log f(x; \theta)}{d\theta} f(x; \theta) dx \\ = E \left(\frac{d^2 \log f(x; \theta)}{d\theta^2} \right) + E \left(\left[\frac{d \log f(x; \theta)}{d\theta} \right]^2 \right) = 0$$

(2) 하나의 기댓값을 이항하면

- $I(\theta) = -E \left(\frac{d^2 \log f(x; \theta)}{d\theta^2} \right) = E \left(\left[\frac{d \log f(x; \theta)}{d\theta} \right]^2 \right)$
- 두 형태 모두 동등한 피셔정보를 나타낸다.

정의

- 유도

3) 한편, $\int_{-\infty}^{\infty} \frac{d \log f(x; \theta)}{d \theta} f(x; \theta) dx = E\left(\frac{d \log f(x; \theta)}{d \theta}\right) = 0$ 이므로,

$$(1) \text{ var}\left(\frac{d \log f(x; \theta)}{d \theta}\right) = E\left(\left[\frac{d \log f(x; \theta)}{d \theta}\right]^2\right) - E\left(\frac{d \log f(x; \theta)}{d \theta}\right)^2 = E\left(\left[\frac{d \log f(x; \theta)}{d \theta}\right]^2\right) - 0 = I(\theta)$$

(2) 즉, 피셔정보는 통계량의 로그우도의 분산 그 자체를 나타낸다.

정의

- 결합분포의 피셔정보

1. 크기 n 인 확률표본 X_1, \dots, X_n 의 결합우도함수가 $L(\theta)$ 이고, 분산이 표본의 정보가 되는 확률변수는

1) $\frac{d \log L(\theta; X)}{d\theta} = \frac{d}{d\theta} [f(X_1; \theta)] + \frac{d}{d\theta} [f(X_2; \theta)] + \dots + \frac{d}{d\theta} [f(X_i; \theta)] = \sum_{i=1}^n \frac{d}{d\theta} [f(X_i; \theta)]$

2) 이 때, 이 확률변수의 **제공의 기댓값**이 그대로 피셔정보가 되므로

(1)
$$E \left[\left\{ \sum_{i=1}^n \frac{d}{d\theta} [f(X_i; \theta)] \right\}^2 \right] = \sum_{i=1}^n E \left\{ \left\{ \frac{d}{d\theta} [f(X_i; \theta)] \right\}^2 \right\}$$
$$= E \left[\left\{ \frac{d}{d\theta} [f(X_1; \theta)] \right\}^2 \right] + E \left[\left\{ \frac{d}{d\theta} [f(X_2; \theta)] \right\}^2 \right] + \dots + E \left[\left\{ \frac{d}{d\theta} [f(X_i; \theta)] \right\}^2 \right]$$

(2) 위 확률표본들은 **동일한 분포에서 추출** 되었으므로

$$= E \left[\left\{ \frac{d}{d\theta} [f(X_1; \theta)] \right\}^2 \right] + E \left[\left\{ \frac{d}{d\theta} [f(X_1; \theta)] \right\}^2 \right] + \dots + E \left[\left\{ \frac{d}{d\theta} [f(X_1; \theta)] \right\}^2 \right]$$

$= nI(\theta)$

2. 즉, 결합분포의 피셔정보는 표본 크기만큼 n 배가 된다.

정의

- 라오 크래머 하한

1. 다변량 확률표본 X_1, \dots, X_n 이 공통 분포에서 추출된 iid라고 가정하자.

1) $Y=u(X_1, \dots, X_n)$ 인 통계량이고, 이 때 $E(Y) = E[u(X_1, \dots, X_n)] = k(\theta)$ 라고 하자. 그러면

$$var(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)} \text{ 이다.}$$

2) Y 의 평균을 $\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(X_1, \dots, X_n) f(X_1; \theta) \dots f(X_n; \theta) dx_1 \dots dx_n$ 이라고 하면

(1) 이를 θ 로 미분하면

$$\begin{aligned} & - \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(X_1, \dots, X_n) f(X_1; \theta) \dots f(X_n; \theta) dx_1 \dots dx_n \\ & = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(X_1, \dots, X_n) \left[\sum_{i=1}^n \frac{1}{f(X_i; \theta)} \frac{df(X_i; \theta)}{d\theta} \right] dx_1 \dots dx_n \\ & = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} u(X_1, \dots, X_n) \left[\sum_{i=1}^n \frac{d \log f(X_i; \theta)}{d\theta} \right] \prod_{i=1}^n f(X_i; \theta) dx_1 \dots dx_n \end{aligned}$$

정의

- 라오 크래머 하한

2. $Z = \frac{d \log f(X_i; \theta)}{d\theta}$ 로 놓으면, $E(Z) = 0$ 이고 $\text{var}(Z) = nI(\theta)$ 이다.

$$\begin{aligned} 1) \quad & \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} u(X_1, \dots, X_n) \left[\sum_{i=1}^n \frac{d \log f(X_i; \theta)}{d\theta} \right] \prod_{i=1}^n f(X_i; \theta) dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} YZ \prod_{i=1}^n f(X_i; \theta) dx_1 \cdots dx_n = E(YZ) \text{이고,} \end{aligned}$$

(1) $k'(\theta) = E(YZ) = E(Z)E(Y) + \rho\sigma_Y nI(\theta)$ 이므로 $E(Z) = 0$ 을 이용하면

$$(2) \quad k'(\theta) = \rho\sigma_Y \sqrt{nI(\theta)}, \quad \rho = \frac{k'(\theta)}{\sigma_Y \sqrt{nI(\theta)}}$$

2) ρ 는 상한이 1이므로, $1 \geq \frac{k'(\theta)}{\sigma_Y \sqrt{nI(\theta)}}$ 따라서 $\sigma_Y \geq \frac{k'(\theta)}{\sqrt{nI(\theta)}}$ 이다.

정의

- 라오 크래머 하한

3. 정리하면

- 1) 피서 정보는 해당 통계량이 전제하고 있는 확률변수(Y = 평균이라면, X 는 정규분포) 에
서 해당 모수(모평균)가 가질 수 있는 가장 이상적인 분산을 나타낸다.
- 2) 라오 크래머 하한은
 - (1) 확률변수의 이상적 분산과,
 - (2) 통계량 자체의 함수인 $(E[\frac{d\text{통계량}}{d\theta}])^2$ 의 비율을
 - (3) 해당 통계량의 최저 분산으로 설정해준다.

정의

- 근사효율성

1. X_1, \dots, X_n 이 pdf $f(x; \theta)$ 를 갖는 iid라고 하자.

1) $\hat{\theta}_{1n} = \hat{\theta}_{1n}(X_1, \dots, X_n)$ 을 $\sqrt{n}(\hat{\theta}_{1n} - \theta_0) \xrightarrow{D} N(0, \sigma_{\hat{\theta}_{1n}}^2)$ 인 θ_0 의 추정량이라고 한다면

2) 근사적 효율성은 $\frac{\frac{1}{I(\theta)}}{\sigma_{\hat{\theta}_{1n}}^2} = e(\hat{\theta}_{1n})$ 으로 정의한다.

(1) 즉, **확률변수의 이상적 분산** 대비 **통계량의 분산**의 비율이다.

3) 근사적 상대 효율성은 $\frac{\frac{1}{I(\theta)}}{\sigma_{\hat{\theta}_{1n}}^2} / \frac{\frac{1}{I(\theta)}}{\sigma_{\hat{\theta}_{2n}}^2} = \frac{\sigma_{\hat{\theta}_{1n}}^2}{\sigma_{\hat{\theta}_{2n}}^2}$ 으로 한다.

정의

• Mle 추정량의 신뢰구간

1. 실제로 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta)})$ 을 만족한다.

1) 로그우도함수의 1계 미분을 2차 테일러 전개하면

$$2) \quad l'(\hat{\theta}_n) = l'(\theta_0) + l''(\theta_0)(\hat{\theta}_n - \theta_0) + \frac{1}{2}l'''(\theta_n^*)(\hat{\theta}_n - \theta_0)^2$$

(1) 이 때, $l'(\hat{\theta}_n) = 0$ 이므로, 다시 정리하면

$$- \sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{\frac{l'(\theta_0)}{\sqrt{n}}}{-\frac{l''(\theta_0)}{n} - \frac{l'''(\theta_n^*)(\hat{\theta}_n - \theta_0)^2}{2n}}$$

(2) 중심극한정리에 의해 $\frac{l'(\theta_0)}{\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{d \log f(X_i; \theta)}{d\theta} \rightarrow N(0, I(\theta))$ 이고

(3) 대수의 약법칙에 따라 $\frac{1}{n} \sum_{i=1}^n \frac{d^2 \log f(X_i; \theta)}{d\theta^2} \rightarrow E\left(\frac{d^2 \log f(X_i; \theta)}{d\theta^2}\right) = I(\theta)$ 이다.

정의

- Mle 추정량의 신뢰구간

1. 실제로 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta)})$ 을 만족한다.

3) 남은항인 $\frac{-l'''(\theta_n^*)(\hat{\theta}_n - \theta_0)^2}{2n}$ 를 살펴보면

(1) $|-l'''(\theta_n^*)| \leq \frac{1}{n} \sum_{i=1}^n \left| \frac{d^3 \log f(X_i; \theta)}{d\theta^3} \right| \leq \frac{1}{n} \sum_{i=1}^n M(X_i)$ 이다.

(2) 대수 법칙에 따라 $\frac{1}{n} \sum_{i=1}^n M(X_i) \rightarrow E_{\theta_0}[M(X)]$ 이다.

(3) 확률 유계를 보기 위하여

$$- n \geq N_1 \Rightarrow P[|\hat{\theta}_n - \theta_0| < C_0] \geq 1 - \frac{\epsilon}{2}$$

$$- n \geq N_2 \Rightarrow P\left[\left|\frac{1}{n} \sum_{i=1}^n M(X_i) - E_{\theta_0}[M(X)]\right| < 1\right] \geq 1 - \frac{\epsilon}{2} \text{ 인 } N_1, N_2 \text{ 를 선택하고}$$

(4) $n \geq \max\{N_1, N_2\} \Rightarrow P[|-l'''(\theta_n^*)| < 1 + E_{\theta_0}[M(X)]] \geq 1 - \frac{\epsilon}{2}$ 이므로 $-l'''(\theta_n^*)$ 는 확률유계이다.

(5) 따라서 $(\hat{\theta}_n - \theta_0)^2 \rightarrow 0$ 이다.

정의

- Mle 추정량의 신뢰구간

1. 실제로 $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0, \frac{1}{I(\theta)})$ 을 만족한다.

2. 위 정리를 이용하면

1) $(1-\alpha) = P(z_{\alpha/2} < \sqrt{n}(\hat{\theta} - \theta_0) \sqrt{I(\theta)} < z_{1-\alpha/2})$
 $= P(\hat{\theta} - z_{\alpha/2} \frac{1}{\sqrt{nI(\theta)}} < \theta_0 < \hat{\theta} - z_{1-\alpha/2} \frac{1}{\sqrt{nI(\theta)}})$

2) 이 때, $I(\hat{\theta}) \xrightarrow{p} I(\theta)$ 이므로, $P(\hat{\theta} - z_{\alpha/2} \frac{1}{\sqrt{nI(\hat{\theta})}} < \theta_0 < \hat{\theta} - z_{1-\alpha/2} \frac{1}{\sqrt{nI(\hat{\theta})}})$ 로 대체하면

(1) 신뢰구간은 $[\hat{\theta} - z_{\alpha/2} \frac{1}{\sqrt{nI(\hat{\theta})}}, \hat{\theta} - z_{1-\alpha/2} \frac{1}{\sqrt{nI(\hat{\theta})}}]$ 이다.